

Minimális költségű feszítőfák

➤ 2020. Ősz – Szita B.

1. BEVEZETÉS

Ebben a fejezetben ismertetjük a feladatot és mutatunk rá két (igen hasonló) absztrakt megoldási stratégiát, amit majd a későbbi fejezetekben fogunk konkrétabb, implementációközelibb szinten részletezni.

1.1. FELADAT

Szemléletesebben: adott egy hálózat, amiben a csúcsok közötti összeköttetésekre több alternatíva is van. Pl. egy autópálya-hálózat lehetséges nyomvonalai, mindre költségbecsléssel. Válasszuk ki, azokat az összeköttetéseket, amikkel a legkisebb összköltséggel az összes pontot a közös hálózatra tudjuk kapcsolni.

Hivatalosabban: adott egy **összefüggő, irányítatlan, élsúlyozott** gráf. Keressük olyan *részgráfját*, aminek a csúcsai azonosak az eredeti gráf csúcsaival, a részgráf *fa* (e kettő feltétel jelenti azt, hogy „feszítőfa”), és éleinek **összesített súlya minimális**.

- ❖ Miért összefüggő? – mert nem lehetne feszítőfája, ha nem lenne az
- ❖ Miért irányítatlan? – mert általában ezen feladatoknak (közmű-vezetékek, autópálya-építés, stb.) így van értelmük; egyébként irányított gráfokra a lenti módszerek nem is működnének!
- ❖ Miért élsúlyozott? – megint csak: általában így értelmesek a való életből vett feladatok, viszont az ismert algoritmusok élsúlyozatlan esetre is működőképesek, viszont ilyenkor a kisebb komplexitású szélességi bejárás is előállítaná a megoldást. Az élsúlyok lehetnek negatívak is

Angolul *Minimum Spanning Tree* (MST).

1.2. ÁLTALÁNOS ALGORITMUS

Ezt a részt az előadó honlapján megtalálható hivatalos jegyzettel együtt, azt kiegészítve olvassátok. A pontos definíciókat itt nem is közlöm, a szimbólumok és fogalmak magyarázatára szorítkozom.

Az alapalgoritmus a következőképpen szól:

1. Vegyünk egy üres élhalmazt
2. $n-1$ alkalommal vegyünk ehhez hozzá mindig egy „biztonságosan hozzávehető” élt
3. A végén a részgráf csúcsai az eredeti gráf csúcsai, az élei az így felépített élhalmaz lesznek

Jelölések:

- ❖ Az eredeti gráf legyen $G = (V, E)$. V a csúcsok (vertices), E az élek (edges) halmaza
- ❖ Legyen $n = |V|$
- ❖ Az épülő élhalmazt majd A -nak hívjuk
- ❖ A kész feszítőfát T -vel (tree) jelöljük, ami egy (V, T_E) pár, azaz a csúcsai az eredeti gráf csúcsai (ezért nincs alsó indexezés), az éleire pedig igaz, hogy T_E részhalmaza E -nek (azaz G éleinek – ez nem feltétlen valódi részhalmaz-viszony, mert G lehet, hogy eredetileg is fa volt)
- ❖ A végén $A = T_E$ lesz

- ❖ Az MST a *minimum spanning tree* kifejezés rövidítése, ez a tulajdonság lesz igaz T-re (tulajdonság, mert az ilyen részfa nem feltétlen egyedi)

Két kérdés adódik: miért $n-1$ kör van és mi az a „biztonságosan hozzávehető”?

- ❖ $n-1$ élet veszünk fel, mert n csúcs van, egy n csúcsú fának biztosan $n-1$ éle van
- ❖ *Biztonságosan hozzávehető* egy él, ha egy A-hoz megfelelően megválasztott vágásban könnyű él

Ez persze újabb kérdéseket vet fel... Mi az a vágás? Hogy válasszam meg A-tól függően? Mi az, hogy egy él egy vágásban könnyű?

- ❖ A „vágás” a gráf csúcsainak két **nemüres** részhalmazra való bontása, osztályozása. Minden csúcs pontosan az egyikbe kerül
- ❖ A lehetséges vágások közül nekünk egy olyat kell választani, ami *elkerüli* A-t
- ❖ Ha van egy vágás, ami *elkerüli* A-t, akkor a vágás egyik *legkisebb súlyú* élet nevezzük *könnyűnek*

Oké..., most már tudunk majdnem mindent, de mi az, hogy a „vágás elkerüli az élhalmazt” és mikor a vágás éle egy él?

- ❖ Akkor *kerüli el* a vágás A-t, ha A **minden** éle (A továbbra is egy élhalmaz) olyan, hogy a két végpontja *ugyanabban* a halmazban van (ezek pedig csúcshalmazok). Azaz a vágás két részhalmaza között nem lehet A-beli él
- ❖ Ezt úgy mondjuk szépen, hogy A egyik éle se *keresztezi* a vágást (a keresztezés jelentené azt, hogy a két halmaz között megy az él)
- ❖ Az, hogy a vágás éle, az pedig azt jelenti, hogy a vágásban szereplő két csúcshalmaz között megy, azaz a már bevezetett fogalommal élve keresztezi azt


Foglaljuk össze:

- ❖ Tegyük $n-1$ -szer a következőt:
 - ❖ Vágjuk fel két részre a csúcsokat úgy, hogy az eddigi feszítőfa-élek ne menjenek a két halmaz között (ezt az elején triviális, aztán egyre nehezebb megcsinálni, de nyilván minden körben megvalósítható)
 - ❖ A két halmaz között futó élek közül válasszuk ki az egyik legolcsóbbat és vegyük a feszítőfához

Ekkor nyilván mindig a *legolcsóbb* olyan élt választjuk, ami egy addig leválasztott részt az épülő feszítőfába integrál, így hát minden csúcsot végül is a legolcsóbb éllel értünk el.

1.3. PÉLDA

Tekintsük az alábbi gráfot:



Élsúlyozott, összefüggő, irányítatlan, tehát a fenti algoritmus alkalmazható.

Lévéen 6 csúcsa van, 5 körben fogjuk elkészíteni a fát.

A következőkben a vágásokat abszolút „önkényesen” választom, semmilyen sorrend nincs kőbe vésve.

Tehát A lesz a minden körben bővülő *élhalmaz*, S és $V \setminus S$ lesz a *vágás*.

1. kör

- ❖ $A = \{\}$
- ❖ $S = \{A, B, C\}$, következésképp $V \setminus S = \{D, E, F\}$
- ❖ A vágást keresztező élek: (B, D) , (B, E) , (C, E)
- ❖ Ebből a minimális, ezt vesszük A -hoz: **(B, E)**

2. kör

- ❖ $A = \{(B, E)\}$
- ❖ S nem lehet ugyanaz, mert a (B, E) él már keresztezne A -ra
 $\rightarrow S = \{A, C\}$, $V \setminus S = \{B, D, E, F\}$
- ❖ A szóba jöhető élek: (A, B) , (B, C) , (C, E)
- ❖ Minimális: **(A, B)**

3. kör

- ❖ $A = \{(A, B), (B, E)\}$
- ❖ $S = \{A, B, E\}$, $V \setminus S = \{C, D, F\}$
- ❖ Élek: (A, C) , (B, C) , (B, D) , (C, E) , (D, E) , (E, F)
- ❖ Minimális: **(D, E)**

4. kör

- ❖ $A = \{(A, B), (B, E), (D, E)\}$
- ❖ $S = \{A, B, C, D, E\}$, $V \setminus S = \{F\}$
- ❖ Élek: (D, F) , (E, F)
- ❖ Minimális: **(E, F)**

5. – utolsó – kör

- ❖ $A = \{(A, B), (B, E), (D, E), (E, F)\}$
- ❖ $S = \{A, B, D, E, F\}$, $V \setminus S = \{C\}$
- ❖ Élek: (A, C) , (B, C) , (C, E)
- ❖ Minimális: **(B, C)**

Ezzel a feszítőfa élei: $\{(A, B), (B, C), (B, E), (D, E), (E, F)\}$

A példában azt láthattuk, az A halmaz folyamatosan szomszédos csúcsokkal „terjeszkedik”. Ez a fajta működés nem törvényszerű, elvileg *szigetszerűen* is létrejöhet a végeredmény (a *Prim-algoritmus* ilyen terjeszkedős lesz, a *Kruskal* pedig inkább szigetes).

1.4. PIROS-KÉK ALGORITMUS [KIEGÉSZÍTŐ ANYAG]

A következőkben ismertetett algoritmus csupán egy másik megfogalmazás, szemléltetés a minimális feszítőfa keresési problémára. Ez semmilyen formában nem lesz visszakérdezve, csak mint érdekesség szerepel itt, illetve talán segít egy más szögből megvilágítani az eddigieket, elmélyíteni a tanultakat.

Vezessük be az élekre a „piros” és „kék” színezést. Kékek lesznek azok az élek, amik *biztosan* a feszítőfa részei és pirosak, amelyek *biztosan nem*.

Kezdetben minden él *fehér*. Az algoritmus e db körből áll, ennek során mindig egy élt színezzünk be, e az élek száma. Ami egyszer be lett színezve valamilyenre, már olyan is marad.

A piros élek meghatározásához használjuk a **piros szabályt**:

- ❖ Vegyünk egy kört, ami *nem* tartalmaz piros élt (kéket tartalmazhat), ennek a **legnagyobb** költségű élet fessük pirosra

Logikus, hiszen a kör minden éle biztos nem lesz a *feszítőfa* része, és akkor már a legdrágábbat hagyjuk ki (lehet, hogy többet is ki fogunk, ha az másik kör része is), a feladat végső soron a körök eliminálása.

A kék élekhez a **kék szabályt** használjuk:

- ❖ Vegyük a csúcsoknak egy X *nem* üres részhalmazát, úgy, hogy az X -ből ne vezessen ki kék él (nem kell, hogy X összefüggő legyen, nem kell, hogy benne kék élek fussanak), a **legkisebb** kivezető élet fessük kékre

Érthető, hiszen ha egy *csúcshalmaz* még nem volt rácsatlakoztatva a rendszerre, érdemes a legolcsóbb él mentén ezt megtenni.

A szabályokat lehet bármilyen sorrendben alkalmazni.

Világos, hogy az előző részben tárgyalt alapalgorithmus gyakorlatilag a kék szabályok ismétlését jelenti.

- ❖ Az A élhalmaz a kék élek egyre gyarapodó halmaza
- ❖ A vágás az X és a $V \setminus X$ mentén jön létre, hiszen nem vezethet X és $V \setminus X$ között kék (A -beli) él, azaz a vágásnak *el kell kerülnie* a kék éleket
- ❖ Most az X -en kívüli *legolcsóbb* élt adjuk hozzá a kék élekhez, azaz A -hoz hozzáadjuk az X és $V \setminus X$ közötti *legolcsóbb* élt: azaz azt a *legolcsóbb* élt, ami *keresztezi* a vágást, azaz a *könnyű* élt!

Nézzünk egy lejátszást a fenti példára!

1.

- ❖ *Piros szabály*
- ❖ $\{A, B, C\}$ egy kör, nincs piros él, legyen hát a legdrágább, (A, C) piros!

2.

- ❖ *Kék szabály*
- ❖ $\{F, B, C\}$ egy tetszőleges nem üres halmaz, amiből nem vezet ki kék él, a legolcsóbb kivezető él, a (B, E) legyen kék

3.

- ❖ *Piros szabály*
- ❖ $\{D, E, F\}$ egy kör, legyen (D, F) piros

4.

- ❖ *Kék szabály*
- ❖ $\{B, E, A\}$, legyen (D, E) kék

5.

- ❖ *Piros szabály*
- ❖ $\{B, C, E\}$, (C, E) piros

6.

- ❖ *Kék szabály*
- ❖ $\{A, C\}$, pl. (A, B) lehet kék

7.

- ❖ *Piros szabály*
- ❖ $\{B, D, E\}$, legyen (B, D) piros

8.

- ❖ *Kék szabály*
- ❖ $\{C, F\}$, legyen (B, C) kék

9.


- ❖ *Kék szabály* (nincs már kör)
- ❖ $\{F\}$, (E, F) legyen kék

Tehát a kék élek: $\{(B, E), (D, E), (A, B), (B, C), (E, F)\}$, pontosan mint az előző megoldással.

Megjegyzések: nem kell felváltva alkalmazni a *piros* és *kék* szabályokat; ha elérjük az $n-1$ kék élt, akár le is lehet állítani az algoritmust; a körök csúcsszáma persze nem kötelező, hogy mindig 3 legyen.

1.5. KÉRDÉSEK

- ❖ Miért nehéz így implementálni ezeket az algoritmusokat?
- ❖ Végezd el a fenti algoritmusokat ezen a gráfon:



2. PRIM-ALGORITMUS

Járník ill. Prim algoritmus a könnyen implementálható, mohó algoritmus a fenti probléma megoldására. Az alábbiakban ezt ismertetjük.

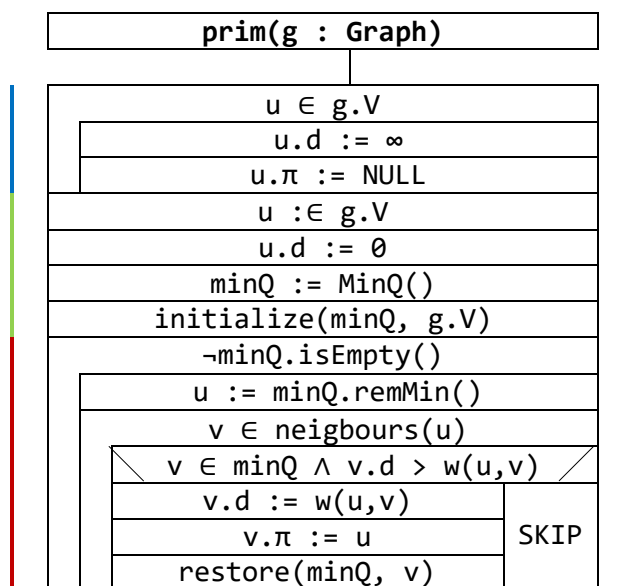
2.1. ALGORITMUS

Véletlenszerűen kijelölünk egy kezdőelemet („:ε” – *nemdeterminisztikus értékválasztás*), és abból iterálva, *lokális optimumok* szerint mindig egy-egy új csúcsot húzunk a készülő fába. Gyakorlatilag a *Dijkstra-algortmussal* azonos a módszer, csak itt nem az utat, hanem a „rendszerbe való beépítés” költségét minimalizáljuk, azaz azt, hogy egy adott még nem elérhető csúcsot, milyen **él** felvételével tudjuk a legolcsóbban bevenni. A kezdőcsúcs opcionálisan akár paraméter is lehet.

Ez a *piros-kék algoritmusra* vonatkozóan csak és kizárólag a kék szabályok ismételtetését jelenti, mégpedig olyan X halmazzal, ami azokat a csúcsokat tartalmazza, amik nincsenek a $\min Q$ -ban. Ez a halmaz mindig eggyel bővül, és mindig azt az élt „színezzük kékre”, amelyik a frissen X -be került, azaz „lezárt” csúcsot az eddigi rendszerre köti. A *Prim-algoritmusban* n kör van, de összesen $n-1$ élt húzunk be, hiszen amikor X egy elemű (első kör után), azt az egy elemet még nem volt mire rákötni.

A tanult, „hivatalos” elméleti háttéralgoritmusra nézvést pedig azt mondhatjuk, hogy a mindenkori vágás a $\min Q$ és a $V \setminus \min Q$ elemei között megy (legalábbis az első kör után, amikor már nem üres az egyik halmaz), azaz a már lezárt csúcshalmaz egyre terjeszkedik. A fentihez hasonlóan, mindig a frissen a $\min Q$ -ból kikerült elemet a többire rávezető él lesz a könnyű, azaz a hozzáveendő.

Fontos tehát érteni, hogy nem akkor történik a „kék szabály” vagy a „könnyű él hozzáadása” alkalmazás, amikor frissítjük egy csúcs (d, π) -párját, hanem amikor „jóváhagyjuk” egy csúcs (d, π) -értékeit akkor, amikor kivesszük azt a $\min Q$ -ból.



A **kék** részben inicializáljuk minden csúcs szülőjét ismeretlenre és árát végtelenre. Csak a kezdőcsúcs szülője marad NULL, az ára semelyik csúcsnak sem lesz a végére végtelen.

A **zöld** részben kiválasztjuk a *tetszőleges* kezdőcsúcsot, elkönyveljük, hogy ez ingyen a *fa* része, létrehozunk egy *minimum prioritásos* sort és inicializáljuk azt, azaz bepakoljuk a kezdőcsúcsot 0-s és az összes többi végtelenes prioritási értékkel.


A **vörös** rész a ciklus, aminek során a kezdetben n elemű prioritásos sorból mindig az aktuálisan legolcsóbb csúcsot kivéve csúcsról csúcsra feldolgozzuk a gráfot. Végignézzük az adott csúcs *kimenő* éleit, és ha úgy tűnik, ebből a csúcsból olcsóbb úton tudunk eljutni egy eddig még nem

véglegesített (esetleg eleve még nem is látogatott) másik csúcsba, akkor azt frissítjük. Ilyenkor az új prioritások mentén a sort is újra kellhet rendezni.

Implementációjára hasonló megjegyzésekkel élhetünk, mint a *Dijkstra* esetében.


2.2. PÉLDA

Futtassuk le a *Prim*-algoritmust az alábbi gráfon, minden körben jelöljük d -t, π -t és $\min Q$ -t.



Kör	minQ	(d, π)					
		A	B	C	D	E	F
INIT	$\langle (A, 0), (B, \infty), (C, \infty), (D, \infty), (E, \infty), (F, \infty) \rangle$	$(0, \emptyset)$	(∞, \emptyset)	(∞, \emptyset)	(∞, \emptyset)	(∞, \emptyset)	(∞, \emptyset)
A	$\langle (B, 1), (D, 3), (C, 4), (E, \infty), (F, \infty) \rangle$	KÉSZ	$(1, A)$	$(4, A)$	$(3, A)$		
B	$\langle (C, 2), (D, 3), (E, 4), (F, \infty) \rangle$		KÉSZ	$(2, B)$		$(4, B)$	
C	$\langle (E, 1), (D, 3), (F, \infty) \rangle$			KÉSZ		$(1, C)$	
E	$\langle (D, 1), (F, 5) \rangle$				$(1, E)$	KÉSZ	$(5, E)$
D	$\langle (F, 5) \rangle$				KÉSZ		
F	$\langle \rangle$						KÉSZ

Íme az *MST*:



2.3. FELADATOK

- ❖ Egy n csúcsú gráfban egy adott csúcs d értéke minimum és maximum hányszor kaphat új értéket a *Prim*-algoritmus futása során?
- ❖ d és π közül valamelyik elhagyható-e?
- ❖ Beszéljük meg, milyen implementációnál mit és milyen lépésszámmal csinál a `restore()` függvény
- ❖ Játszd le a *Prim*-algoritmust az előző fejezet feladatában megadott gráfra

3. KRUSKAL-ALGORITMUS

A fenti probléma egy másik lehetséges megközelítéssel vett megoldása. A *Prim* esetében egy csúcsalmazhoz vettük hozzá mindig a legalkalmasabb újabb csúcsot, most pedig a legolcsóbb élek szerint fogunk haladni.

3.1. ALGORITMUS

Két verziót is mutatok, a második struktogram bizonyos átnevezések mellett gyakorlatilag megfelel az előadásanyagbeli változatnak – ez az optimalizált, helyes verzió.

A struktogramokban látható \emptyset most *üres halmaz* jel, nem *nullpointer*.

Piros rész a lenti struktogramban: adott egy gráf (*g*), amihez egy élhalmazt, a leendő *MST* éleit építjük, ezt hívtuk az előadásjegyzetben *A*-nak, itt *mstEdges*-nek.

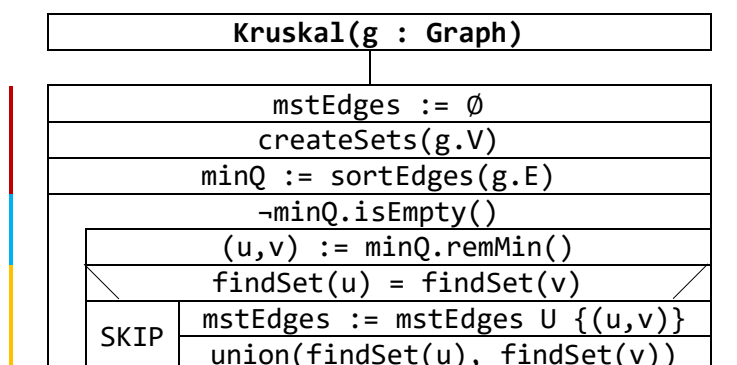
Egyrészt kiindulunk az *üres élhalmazból*, másrészt minden csúcshoz kezdetben egy egyelemű halmazt (*komponens*t rendelünk), így minden csúcs önmagában egy *fa* – ez a *createSets()* függvény, praktikusán minden csúcshoz egy egyre növekvő, egyedi számot rendel pl. egy tömbbel.

Készítünk egy *minimum prioritásos* sort az élek súlyára nézve, majd eszerint vesszük előbb a legolcsóbbat, majd a következő legolcsóbbat, stb., végül a legdrágább élt. Ez hasonló a *Prim-algoritmus*ban látottakhoz, tehát ez az algoritmus is *mohó*. Két nagy különbség van: itt élek szerint építjük fel a prioritásos sort, míg ott csúcsok szerint; illetve itt a sorrend az inicializálás után *nem változik*, míg ott időről időre *frissíteni* kellett a prioritásos sort. Ebből következően most a prioritásos sort simán reprezentálhatjuk egy *rendezett tömb*bel is.

Kék rész: egy ciklussal megyünk, amíg van *feldolgozatlan* él. Kivesszük a „következő” legolcsóbb élet.

Sárga rész: megnézzük, ezen legolcsóbb él két végpontjának halmazai azonosak-e. Ha igen, akkor ezt az élet nem vesszük a fába, hiszen olyan két csúcs között menne, amik már eddig is elérhetőek voltak egymásból a *fa* élein át – azaz ez *kört* hozna be a készülő *feszítőfába*, ami miatt az elveszítené *fa* jellegét.

Ha viszont most találtuk meg két eddig egymásból nem elérhető csúcs (*komponens*) közötti legolcsóbb összekötő élt, akkor ezt bátran a *feszítőfához* adhatjuk. Ekkor az algoritmus számára tudatni kell azt is, hogy mostantól ez a két csúcs egy komponensbe került – persze az összes egy komponensbeli egyéb csúcsokkal együtt – erről szól a *union()* függvény.



g csúcsai és az *mstEdges* együtt minden pillanatban egy *feszítőerdőt* határoznak meg, ez egy *invariáns* az algoritmusra. Kezdetben ez csupa egycsúcsú *fa*. Az összevonások nyomán a végére eljutunk az egyetlen *komponens*hez, egyetlen *fához*, ami innen nyilvánvalóan *feszítőfa* is. A minimálissága pedig az alábbiakból következik:

Az *absztrakt algoritmus*nak ez úgy felel meg, hogy amikor egy olyan adott (u, v) él kerül sorra, amit ténylegesen hozzá is adom az élhalmazhoz, egy olyan vágást tekintek, aminek az egyik halmazában u és komponense szerepelnek, a másikban a többi csúcs. Világos, hogy nem lehet olyan *mstEdges*-beli él, ami keresztezné ezt a vágást, mert akkor u komponense nagyobb lenne. Eközött a két komponens között fut az (u, v) él. Az ilyenek közül ez a legolcsóbb, azaz a könnyű él.

A *piros-kék algoritmus*nak pedig úgy felelünk meg, hogy ha (u, v) -t nem vesszük hozzá, akkor legyen a kör u komponense az (u, v) éllel kiegészülve, ebben szükségképpen utóbbi a *legdrágább*, hiszen a többi előbb lett kivéve a *prioritásos sorból*; ha az élt hozzávesszük, akkor pedig u komponense legyen az a csúcshalmaz, amiből nem vezet ki kék él – azaz a *feszítőfa* éle, hiszen ha kivezetne, nagyobb lenne a komponens. Most ha épp (u, v) van soron, akkor biztosan ez az él a legolcsóbb még szintelen, tehát kékre kell színezni, avagy a fába kell építeni.

Tehát az algoritmus valóban a *minimális költségű feszítőfát* adja így meg, de mennyire *hatékony* vajon?

3.2. OPTIMALIZÁLÁS

Piros rész: az *üres halmaz* létrehozása *konstans*. Minden csúcshoz egy egyedi szám rendelése a csúcsok számával korrelál, tehát $\Theta(n)$ -es. Az élek sorbarendezése $\Theta(e \times \log(e))$.

Mivel csak összefüggő gráfra van értelme a feladatnak, e legalább $n-1$, tehát az kimondható, hogy $n \in O(e)$. A fordított irány, s ezzel a Θ már nem *feltétlen* lesz igaz (mert lehet *sűrű* a gráf).

De az biztos, hogy emiatt az egész **piros** rész nagyságrendileg $\Theta(e \times \log(e))$.

A **kék** rész *ciklusánál* nyilván maga a *feltétel* kiszámítása *konstans*, a *remMin()* is ebben az esetben tud konstans lenni, viszont ha ezzel minden körben egy élt veszünk ki a sorból, a *ciklusmag* annak eredeti elemszámaszor, azaz e -szer fog lefutni.

Ezen belül (**sárga**) az *mstSet*-hez *unió*zás triviálisan *konstans*. A *union()* is lehet *konstans* (ez nem evidens, később indoklom). A *findSet()* pedig $O(\log(n))$ -es (ezt is később indoklom).

Tehát ott tartunk, hogy a ciklus $O(e \times \log(n))$, összességében a $\Theta(e \times \log(e))$ egy jó nagyságrend.

Tudunk-e ezen *hatékonyítani*?

Egyrészt, vezessünk be egy *segédváltozót*, ezt én *components*-nek fogom hívni, az előadásjegyzetben k . Ezzel számoljuk, hány darab *komponens*, hány *részfa* van épp a végső *feszítőfa* aktuális *részgráfjában*. Kezdetben ez nyilván n , és minden olyan körben csökken, amikor összevonunk két fát. Nyilván akkor vagyunk kész, ha $n-1$ -szer csökkentettük, azaz, ha az értéke 1 lesz. Összességében így, n -ről indulva és csökkentve hatékonyabban használható ez a *segédváltozó*, mintha egy Θ -ról induló, növvő, az élek számát számoló változót tartanánk karban.

Előrebb nagyságrendben nem vagyunk, mert lehet olyan gráf, ahol ezek után is ez egy e -s ciklus.

A másik javítás a *findSet()* kirakása változóba, hogy csak egyszer fusson le, hiszen ez nem *konstans*.

A harmadik javítás pedig a *minQ* esetében mégis a *kupac* használata. Ott ugyanis bár nem *konstans* a *remMin()*, hanem $O(\log(e))$, de az inicializálás is csak $\Theta(e)$.

Tehát így ott tartunk, hogy a **piros** rész $\Theta(1) + \Theta(n) + \Theta(e) + \Theta(1) = \Theta(n + e)$.

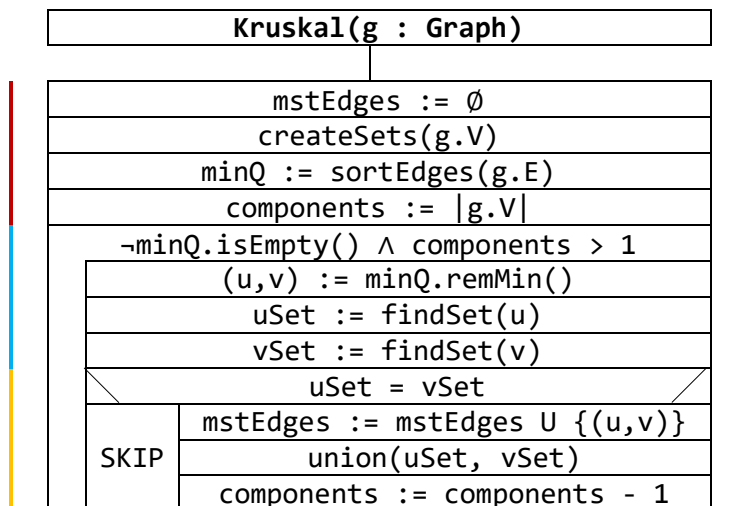
A **kék** rész $O(e)$ -s szorzót hoz be.

A belseje $O(\log(e)) + O(\log(n)) + O(\log(n)) + 1 + 1 + 1 + 1 = O(\log(n)) + O(\log(e))$. Az utolsó 4 db konstans a **sárga** rész.

Igen ám, de amúgy $O(\log(n)) = O(\log(e))$. Ha feltesszük, hogy nincsenek párhuzamos élek, az élek száma legfeljebb négyzete lehet nagyságrendileg a csúcsok számának. Ez pedig *logaritmus* alatt csak *konstans* szorzó.

Ez alapján összességében: $\Theta(n + e) + O(e \times \log(n))$ a műveletigény. Ebből a második tag a *domináns*.

Ez pedig a javított algoritmus:



3.3. UNIÓ-HOLVAN (DISJOINT-SET) ADATSZERKEZET

Az adatszerkezetre angolul a *union-find* ill. a *merge-find* kifejezéseket is használják.

Feltettük, hogy a *findSet()* és a *union()* is igen *hatékony* műveletek.

Ez fontos kérdés, mivel a *union()* esetében nem csak *u* és *v* komponensét kell egyesíteni, hanem az összes olyan csúcsét is, ami a két elemmel azonos halmazban volt! Ez látszólag egy *n*-es ciklus lenne (ráadásul egy *e*-s ciklusban).

A *komponenshalmazokat* reprezentáljuk az „*unió-holvan*” adatszerkezettel, ami egy speciális *fa*.

Minden csúcshoz két plusz adatot tárolunk (ez lehet két a csúcsokkal indexelt *tömb*, vagy a csúcsok típusába felvett plusz *adattag* is akár). π és *s* ez a két adattag. π jelentse a *szülő*t (*parent*), ami nem is teljesen korrekt megfogalmazás, ugyanis ez vagy a *szülő*t, vagy a *fa gyökerét* fogja jelenteni. *s* pedig az adott csúcsból, mint *gyökérből* kiinduló *fa mérete* (csúcsszáma) *elcache*-elve. Mind *s*, mind π szempontjából a *gyökércsúcsok* értékei érdekelnek csak minket, a többi csúcsra vetített értéknek abban van szerepe, hogy a *gyökérben* minél *optimálisabban* tudjuk *karban tartani* a két attribútum értékét.


A *createSets()* függvényben tehát minden csúcsnak a π -jét önmagára, az *s*-ét 1-re állítjuk. Ez megfelel a fenti *kontraktus*nak, és ahogy feltételeztük, a csúcsok számára véve *lineáris* műveletigényű.

A *findSet()*-ben megnézzük, a csúcs π -je önmaga-e. Ha igen, akkor ez egy *fa gyökere*, *return*ölünk vele. Ha nem, akkor *rekurzívan* megnézzük a π -jére (*parentjére*) ugyanezt egészen addig, amíg *gyökérre* nem bukkanunk. Mivel cél az, hogy ez a *keresés* minél *gyorsabb* legyen, a *jövőben* is, ezért igyekszünk ezt *optimalizálni*. A keresés során tehát *rekurzív módon famagasságnyi* lépünk felfelé a π értékek mentén. Plusz műveletigény nélkül el tudjuk érni, hogy az út során *látogatott* csúcsok π -je mind *átállítódjon* a közös *szülőre/gyökérre* (az *s*-ek nem változnak). Ez azt jelenti, hogy a *fa gyökerének gyerekszáma* nő, de a *fa magassága* csökken(het). A *gyerekszám* növekedése pedig mindegy, hiszen ebben az irányban sose *nézelődünk*, nem is *tartjuk számon* a *pointereket*. Mindegyik π a *szülő/gyökér felé* mutat, más *pointer* pedig nincs. Ez a művelet tehát *alapvetően logaritmikus*, de ugyanilyen szereposztásban újra meghívva már *konstans* lenne.

A `union()` művelet megnézi melyik fa a *nagyobb* (elemszámra értve, de akár magasságra is nézhetjük – bizonyos jegyzetekben ez így szerepel), és ez alá beszúrja a kisebbiket. Azt tudjuk, hogy a két paraméter két *különböző* fa gyökere (hiszen a `findSet()` ezt kereste, és meg se hívtuk volna a `union()`-t, ha azonos fák lennének érintve). Egyszerűen csak a π mentén beszúrjuk az egyiket a másik alá, valamint az új, közös gyökér esetén az s -t is értelemszerűen, az *invariánst* megtartva frissítjük.

A `findSet()`-nél megadott optimalizációt (ti. a fa kilapítását) a `union()`-ba is beépíthetnénk. Igaz ehhez kéne tárolni gyerek pointereket is és ez nem is lenne *konstans*. Ugyanakkor, így az összes fa 0 vagy 1 magas lenne, ami a másik műveletnél jobb. Mindenesetre a tanult verzióban a `union()` műveletigénye konstans.

3.4. PÉLDA



Kezdetben tehát minden csúcs egy halmaz (*komponens*): $\{A\}$, $\{B\}$, $\{C\}$, $\{D\}$, $\{E\}$.

- ❖ Kiválasztom a legolcsóbb élt: (A,B) , mivel A és B külön halmaz, ezért ezt az élt felveszem és A-t és B-t összevonom: $\{A, B\}$, $\{C\}$, $\{D\}$, $\{E\}$
- ❖ Most a második legolcsóbb: (D,E) , ezek is külön vannak, összevonom hát őket: $\{A, B\}$, $\{C\}$, $\{D, E\}$
- ❖ Most a (B,C) él jön, ez is két külön halmazt köt össze, ezért felveszem és összevonom az érintett halmazokat: $\{A, B, C\}$, $\{D, E\}$
- ❖ Az (A,C) él a következő, de A és C halmaza azonos, ezért ez nem lesz a *legolcsóbb feszítőfa* része
- ❖ Az (A,D) él véglegesíti a feszítőfát: $\{A, B, C, D, E\}$

Az elsőként közölt algoritmus esetén még ebben a sorrendben a (C,D) , a (C,E) és a (B,E) éleket is vizsgálnánk, de persze már nem lesz változás. A *komponensszámolás optimalizáció* pedig megóv minket a felesleges köröktől.

Végül a *feszítőfa* élei: (A,B) , (D,E) , (B,C) , (A,D) . Ez 5 csúcsra 4 él, rendben van.

3.5. FELADATOK

- ❖ Jegyzetből: „Hogyan tudná kifinomultabban értelmezni azt az esetet, ha a Kruskal-algoritmus $k > 1$ (itt: *components* > 1) értékkel tér vissza? Mit jelent a k értéke általában? Tudna-e értelmet tulajdonítani a Kruskal-algoritmus által kiszámolt A (itt: *mstEdges*) élhalmaznak, ha végül $k > 1$ értéket ad vissza?”
- ❖ Miért hatékonyabb így, hogy *components* n -ről indul és csökken, mintha 0-tól indulna és nőne, az élek számát nézné? (kis különbségről van csak szó)
- ❖ Milyen gráfban lesz az optimalizáció után továbbra is e -s ciklus a $\min Q$ -n való végigjárás?

- ❖ „Ez azt jelenti, hogy a fa gyökerének gyerekszáma nő, de a fa magassága csökken(het).” – miért a feltételes mód?
- ❖ Miért jó/jobb, ha a nagyobb fa alá szúrjuk a kisebbet?
- ❖ Feltételezve, hogy a *Prim-algoritmus* műveletigénye *Fibonacci-kupaccal* $O(e + n \times \log(n))$, a *Kruskalé* pedig $O(e \times \log(n))$, melyik a jobb választás és miért?
- ❖ B-szakírányra: miért nem jó választás *terminálófüggvénynek components*? Mi működhet helyette?
- ❖ Futtasd le a *Kruskal-algoritmust* az első fejezet feladatában megadott gráfra, jelöld minden körben a komponenseket!
- ❖ Futtasd le a *Kruskal-algoritmust* a második fejezet példájában megadott gráfra, jelöld minden körben a komponenseket!

TARTALOM

1.	Bevezetés.....	1
1.1.	Feladat.....	1
1.2.	Általános algoritmus.....	1
1.3.	Példa	2
1.4.	Piros-kék algoritmus [kiegészítő anyag]	3
1.5.	Kérdések.....	5
2.	Prim-algoritmus	6
2.1.	Algoritmus.....	6
2.2.	Példa	7
2.3.	Feladatok	7
3.	Kruskal-algoritmus.....	8
3.1.	Algoritmus.....	8
3.2.	Optimalizálás	9
3.3.	Unió-holvan (<i>disjoint-set</i>) adatszerkezet	10
3.4.	Példa	11
3.5.	Feladatok	11